Centro Universitário de Excelência
Sistemas de Informação

OAT 2
Introdução ao Pré-processamento

Biblioteca de Pré-processamento em linguagem de programação Python

Equipe - ITABUNA

Orientador: Lucas Almeida Silva
Autor: Andrey Mota de Oliveira
Claudio dos Santos Junior
Gabriel da Silva e Silva
Louise de Souza Santino

Feira de Santana, 2026

Agenda

O objetivo dessa apresentação é demonstrar o desenvolvimento de uma biblioteca de pré-processamento de dados em Python e sua aplicação no **dataset Spotify Songs for ML & Analysis.**

1. Contextualização (3):
Objetivo, problema e aplicação do que foi feito baseado no dataset.

2. Classificação das Operações e seus tipos (4):
Classificação das operações, destacando suas características.

3. Classes & Métodos (5):
Apresentação das classes e métodos.

4. Restrições (6)
Restrições do dataset.

5. Métodos (7-10):
Aplicação dos métodos no dataset e seus exemplos.

6. Pré-processamento & Resultados (11):
Principais resultados obtidos e considerações sobre o pré-processamento.

7. Considerações Finais e Conclusão (12-14) :
Considerações sobre a limitação do pré-processamemento e conclusão final

Contextualização

● Biblioteca **Python** desenvolvida no desafio do programa de dados da empresa **Dendê Softhouse** para tratar **valores ausentes, categorias e escalas diferentes** que comprometem algoritmos de machine learning.

● Técnicas de **pré-processamento** desenvolvidas com recursos nativos da linguagem de programação **Python** para preparar dados para análise e modelagem.

● Apresentação das técnicas implementadas, estrutura da biblioteca e aplicação no **dataset Spotify Songs for ML & Analysis.**

Classificação dos tipos de operação

● As operações de pré-processamento foram estruturadas em três categorias principais, conforme o tipo de transformação aplicada aos dados, facilitando a aplicação das técnicas de acordo com sua finalidade.

Tratamento de Dados Ausentes	Identificar, substituir ou remover valores nulos
Transformação de Escala	Padronizar ou normalizar valores numéricos
Codificação de Dados Categóricos	Converter valores textuais em representações numéricas

Classes & Métodos Usados

MissingValueProcessor	Scaler	Encoder	Preprocessing
__init__ _get_target_columns isna notna fillna dropna	__init__ _get_target_columns minMax_scaler standard_scaler	__init__ label_encode def oneHot_encode	__init__ _validate_dataset_shape scale encode isna notna fillna dropna

Restrições do Dataset

- Implementação apenas com recursos nativos da linguagem de programação Python.

- Bibliotecas proibidas: numpy, pandas, statistics, sklearn e afins.

- Técnicas devem ser aplicadas manualmente.

- Estrutura obrigatória: dicionário de listas.

- Dataset aplicado deve ser o **Spotify Songs for ML & Analysis**.

- Pré-processamento utilizando operações da biblioteca desenvolvida.

Processamento de Dados Ausentes ou Nulos

isna(self, columns: Set[str] = None)
Exemplo: *Ver problema*

def notna(self, columns: Set[str] = None) -> Dict[str, List[Any]]:
Exemplo: *Pegar dados válidos*

def fillna(self, columns: Set[str] = None, value: Any = 0) -> Dict[str, List[Any]]:
Exemplo: *Corrigir*

def dropna(self, columns: Set[str] = None) -> Dict[str, List[Any]]:
Exemplo: *Apagar*

Processamento de Dados Ausentes ou Nulos

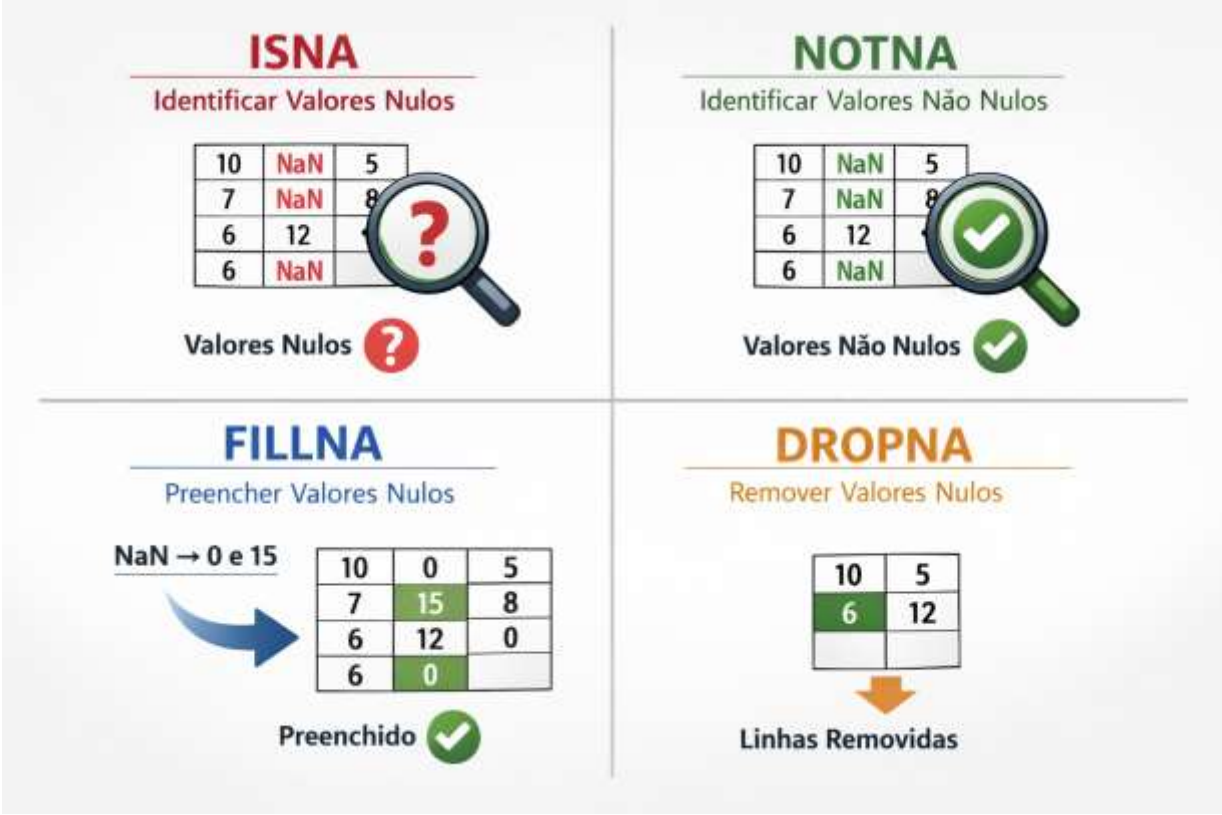

Transformadores de Escala

def minMax_scaler •	• def standard_scaler
Escala fixa (0 a 1)	Média 0, desvio 1
Sensivel a outliers	Lida melhor com outliers
Mantém proporção	Centraliza os dados

≠

$$x' = \frac{x - min}{max - min}$$

$$z = \frac{x - \mu}{\sigma}$$

Codificadores de valores categóricos

label_encode(self, columns: Set[str])
Exemplo: *Quando tem ordem*

def oneHot_encode(self, columns: Set[str]) -> Dict[str, List[Any]]:
Exemplo: *Quando não tem ordem*

- **Estudo de caso**

Um cientista de dados está analisando o dataset track_data_final.csv e precisa codificar duas variáveis categóricas para um modelo de Machine Learning:

Variável	Valores
Explicit	True, False
Album_type	‘álbum’, ‘single’, ‘compilation’

Qual das seguintes abordagens é a mais adequada para codificar essas variáveis?

A) Aplicar Label Encoder em ambas as variáveis.
B) Aplicar Label Encoder em explicit e One-Hot Encoder em album_type.
C) Aplicar One-Hot Encoder em explicit e Label Encoder em album_type.

Pré-processamento do dataset Spotify Songs

```
============================================================
ANÁLISE DE PRÉ-PROCESSAMENTO - SPOTIFY
============================================================
Dataset carregado: 8778 músicas

1. DATASET ORIGINAL: 8778 linhas


2. VALORES NULOS
   Colunas numéricas:
     - artist_popularity: 4 nulos (0.0%)
     - artist_followers: 4 nulos (0.0%)
   Colunas categóricas:

3. TRATAMENTO DE NULOS
   - fillna(value=0): todos os nulos numéricos preenchidos


4. ESCALONAMENTO MIN-MAX
   ANTES:
     track_popularity: min=0.00, max=100.00
     artist_popularity: min=0.00, max=100.00
   DEPOIS (0 a 1):
     track_popularity: min=0.00, max=1.00
     artist_popularity: min=0.00, max=1.00
```

```
5. LABEL ENCODING
   ANTES:
     explicit: 2 categorias
     album_type: 3 categorias
   DEPOIS (valores numéricos):
     explicit: [0, 0, 0, 1, 0]
     album_type: [1, 2, 0, 0, 0]


6. ONE-HOT ENCODING
   Original:
     album_type: ['album', 'single', 'album', 'compilation', 'single']
     explicit: ['TRUE', 'FALSE', 'TRUE', 'FALSE', 'TRUE']
   Após One-Hot (novas colunas):
     album_type_album: [1, 0, 1, 0, 0]
     album_type_compilation: [0, 0, 0, 1, 0]
     album_type_single: [0, 1, 0, 0, 1]
```

Resultados

- Todos os testes passaram

```
----------------------------------------------------------------------
Ran 12 tests in 0.008s

OK
```

Considerações finais

- Uso exclusivo de recursos nativos da linguagem de programação Python limitou o desempenho em grandes volumes de dados.

- Implementação manual exigiu maior cuidado para evitar distorções nas transformações.

- Biblioteca aplicada com sucesso no dataset **Spotify**, tratando valores ausentes, escalas e variáveis categóricas.

- A experiência com implementações manuais reforçou conceitos fundamentais da área.

- É possível construir soluções robustas com Python puro, desde que haja planejamento adequado.

Referências

- BARBETTA, Pedro Alberto; REIS, Marcelo Menezes; BORNIA, Antonio Cezar.**Estatística para Cursos de Engenharia e Informática**. 4. ed. São Paulo: Atlas, 2014.

- KAGGLE. Spotify Songs for ML & Analysis (8700+ tracks). **Dataset de AlyAhmedTS13.** Disponível em: https://www.kaggle.com/datasets/alyahmedts13/spotify-songs-for-ml-and-analysis over-8700-tracks. Acesso em: 15 mar. 2026

- PEDREGOSA, F., VAROQUAUX, G. AND GRAMFORT, A. (2011) "Scikit-learn: Machine Learning in Python", **Journal of Machine Learning Research**, Disponível em: https://jmlr.csail.mit.edu/papers/v12/pedregosa11a.html, Acesso em: 15 mar. 2026.

- WILSON, G. ET AL. (2014) "Best Practices for Scientific Computing**", PLOS Biology,** Disponível em: https://journals.plos.org/plosbiology/article?id=10.1371/journal.pbio.1001745, Acesso em: 18 mar. 2026.